

FINAL TASK

PROJECT BASED INTERNSHIP

Credit Risk Assessment & Default Prediction: A Multi-Model Benchmarking Study

DATA SCIENTIST

Presented by Angga Priambudi





ABOUT COMPANY

Didirikan pada tahun 2002, ID/X Partners memiliki rekam jejak panjang dalam melayani perusahaan di seluruh wilayah Asia dan Australia. Spesialisasi pada industri layanan keuangan, telekomunikasi, manufaktur, dan ritel. Penyedia layanan konsultasi yang berfokus pada solusi Data Analytic and Decisioning (DAD). Menggabungkan manajemen risiko dan pemasaran terintegrasi untuk mengoptimalkan profitabilitas portofolio serta proses bisnis klien. Menawarkan layanan konsultasi dan solusi teknologi komprehensif sebagai one-stop service provider.



DATA UNDERSTANDING

Dataset Overview

Analisis dilakukan terhadap dataset pinjaman historis dengan total 466.285 baris data.

Feature Complexity

Teridentifikasi 75 kolom fitur yang mencakup data demografi nasabah, detail pinjaman, dan riwayat pembayaran.

Data Quality Assessment

- Ditemukan 17 kolom dengan missing values 100%.
- Terdapat indikasi Data Leakage pada fitur pasca-pinjaman (seperti recoveries).



Target Selection

Penentuan variabel target dilakukan secara biner (Good vs Bad Loan) untuk mendukung otomatisasi keputusan kredit.

EDA

EXPLORATORY DATA ANALYSIS

```
... Fitur yang paling berkorelasi dengan Gagal Bayar (Top 5):  
target          1.000000  
recoveries      0.420011  
collection_recovery_fee 0.283151  
int_rate        0.246338  
out_prncp       0.202622  
out_prncp_inv   0.202615  
Name: target, dtype: float64
```



EDA

EXPLORATORY DATA ANALYSIS

Distribusi Target:

- Good Loans (78.9%): Mayoritas nasabah memiliki status pembayaran yang baik.
- Bad Loans (21.1%): Terdapat risiko gagal bayar yang signifikan, memerlukan penanganan class imbalance.


Korelasi Variabel Signifikan:

- Suku Bunga (int_rate): Menunjukkan korelasi positif terhadap gagal bayar; semakin tinggi bunga, semakin tinggi risiko nasabah tersebut.
- Fitur Keuangan: Variabel seperti jumlah pinjaman dan jangka waktu (term) menjadi indikator perilaku kredit yang kuat.

Temuan Kritis: Deteksi variabel pasca-kejadian seperti recoveries yang menunjukkan korelasi semu (kebocoran data) dan harus dieliminasi.

--- Ringkasan Distribusi Target ---

	Count	Percentage (%)
Good Loan (0)	191091	78.9
Bad Loan (1)	50968	21.1



DATA PREPARATION & FEATURE ENGINEERING

Menghapus 17 kolom yang 100% kosong dan kolom dengan tingkat kekosongan > 70%.

Eliminasi fitur Data Leakage (seperti recoveries) untuk menjaga integritas prediksi pada data baru.

Transformasi Fitur:

Missing Values: Imputasi menggunakan nilai median untuk kolom numerik agar tahan terhadap outlier.

Feature Encoding: Mengonversi variabel teks (seperti grade) menjadi angka menggunakan One-Hot Encoding.

Hasil Akhir: Dataset bersih dengan dimensi (242.059 baris, 38 kolom) dan 0 missing values.

```
Pembersihan Selesai.  
Dimensi Data Akhir: (242059, 38)  
Jumlah Missing Values: 0
```

DATA MODELLING

Metodologi: Melakukan komparasi performa antara 6 algoritma berbeda menggunakan metode Stratified Train-Test Split (80:20).

Algoritma yang Diuji:

- 1.XGBoost: Menggunakan metode Gradient Boosting yang optimal untuk data tabular besar.
- 2.LightGBM: Efisien dalam penggunaan memori dan kecepatan training.
- 3.Random Forest: Algoritma ensemble berbasis decision trees.
- 4.Logistic Regression: Sebagai model baseline linear.
- 5.Linear SVM & KNN: Untuk melihat perbandingan berbasis margin dan jarak.

Parameter: Penerapan class_weight='balanced' untuk menangani ketimpangan jumlah nasabah baik dan buruk.

	Model	AUC-ROC	Recall	F1-Score
2	XGBoost	0.965689	0.956445	0.932925
3	LightGBM	0.964744	0.952227	0.934714
1	Random Forest	0.953176	0.928095	0.923655
0	Logistic Regression	0.950396	0.920836	0.922691
4	Linear SVM	0.942680	0.904748	0.915071
5	KNN (Sampled)	0.710125	0.438199	0.582133

EVALUATION

Hasil Metrik Performa (XGBoost - Pemenang):

AUC-ROC: 0.965 (Kemampuan membedakan nasabah sangat akurat).



Recall (Kelas 1): 0.956 (Berhasil menangkap 95.6% nasabah yang berpotensi gagal bayar).

Akurasi: 0.97 (Tingkat ketepatan prediksi keseluruhan).

Feature Importance:

Fitur 'funded_amnt', 'total_pymnt', dan 'int_rate' teridentifikasi sebagai tiga prediktor paling berpengaruh dalam menentukan risiko kredit.

Analisis Confusion Matrix: Model menunjukkan tingkat False Negative yang sangat rendah (444 kasus), yang krusial untuk meminimalisir kerugian bank.



CONCLUSION

Kesimpulan Teknis: Model XGBoost terbukti sangat robust dan objektif dalam memprediksi kegagalan bayar tanpa ada kebocoran data.

Rekomendasi Bisnis:

- Implementasi Pipeline: Mengintegrasikan model ke dalam sistem persetujuan pinjaman otomatis untuk meningkatkan kecepatan keputusan.
- Strategi Risiko: Menggunakan Probability of Default (PD) dari model untuk menyesuaikan penawaran suku bunga sesuai profil risiko nasabah (Risk-Based Pricing).
- Mitigasi Dini: Memprioritaskan penagihan atau bantuan pada nasabah yang memiliki skor risiko tinggi menurut prediksi model.

TERIMA KASIH

KONTAK SAYA



Github

https://github.com/nggapb104/PBI_FinalTask



Email

priambudiangga104@gmail.com

